

Investigación Operativa

Álvaro García Tenorio ¹

11 de agosto de 2017

¹alvgar14@ucm.es

Índice general

Prefacio	VI
I Programación lineal	1
1. Fundamentos teóricos	3
1.1. Planteamiento del problema	3
1.1.1. Forma estándar y formas canónicas	4
1.1.2. Terminología y casuística	7
1.2. Programación lineal y conjuntos convexos	7
1.2.1. Conjuntos convexos. Definición y propiedades	8
1.2.2. Puntos extremos	10
1.2.3. Direcciones extremas	14
1.3. Teoremas fundamentales	16
2. Algoritmo del Símplex	21
2.1. Cambios de base	21
2.1.1. Vectores auxiliares y componentes básicas	21
2.1.2. Costes reducidos y función objetivo	22
2.2. Tabla del Símplex. Pivotajes	23
2.3. Punto extremo inicial	24
2.3.1. Método de las dos fases	25
2.3.2. Método de las penalizaciones (Big M)	26
2.4. Prevención de bucles	26
2.4.1. Criterios de entrada y salida de la base	26
2.4.2. Regla lexicográfica	26
2.4.3. Regla de Bland	28
3. Dualidad	29
II Programación entera	31
4. Modelización	33
5. Ramificación y acotación	35
III Programación no lineal	37
IV Anexos	39
Índice de términos	41

Prefacio

Estas notas son una transcripción (libremente adaptada) de las clases de la asignatura “*Investigación Operativa*”, impartidas por María Inés Sobrón Fernández en el curso 2016–2017 a los cursos de cuarto y tercero de los dobles grados de Matemáticas – Física e Ingeniería Informática – Matemáticas (respectivamente) en la facultad de Ciencias Matemáticas de la Universidad Complutense de Madrid (UCM).

Cualquier aportación o sugerencia de mejora es siempre bienvenida.

Requisitos previos


Para comprender estas notas en su totalidad es necesario tener soltura a la hora de trabajar con bases de espacios vectoriales de dimensión finita y comprender bien las aplicaciones lineales. También es bastante recomendable recordar algunos aspectos del cálculo diferencial en varias variables, no obstante, el texto es bastante autocontenido en ese aspecto.

Agradecimientos

La existencia de estas notas es debida a la amabilidad de Clara Rodríguez Núñez, quien me cedió sus apuntes tomados durante el curso, en los cuales se basa el núcleo de este texto.

Licencia

Esta obra está sujeta a la licencia Reconocimiento-NoComercial-CompartirIgual 4.0 Internacional de Creative Commons. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-nc-sa/4.0/>.



El código fuente de este documento es de libre acceso y se encuentra alojado en <https://github.com/alvarogatenorio/Investigacion-Operativa> para uso y disfrute de todo el que quiera, siempre que se respeten los términos de la licencia.

Parte I

Programación lineal

Capítulo 1

Fundamentos teóricos

La disciplina de la programación lineal cogió fuerza en la segunda guerra mundial, pues era necesario optimizar los escasos recursos de los que se disponían para realizar operaciones militares. En un principio fue impulsada por el ejército británico, con un grupo de investigación dirigido por **Blackett**, quien más adelante ganaría el premio Nobel de física por otros motivos.

Cabe destacar la gran importancia que tuvo la programación lineal en países como Albania, debido, entre otras cosas, a su utilidad a la hora de optimizar los procesos de producción de carbón.

1.1. Planteamiento del problema

De ahora en adelante, consideraremos fijadas las bases canónicas tanto de \mathbb{R}^n como de \mathbb{R} , a no ser que se especifique lo contrario.

Antes de plantear formalmente el problema de la programación lineal, introduzcamos unas definiciones.

Definición 1.1.1 (Vector no negativo). Un vector $x = (x_1, \dots, x_n) \in \mathbb{R}^n$ se dice **no negativo** si todas sus componentes son, como su propio nombre indica, no negativas. Es decir, $x_i \geq 0$ para todo $i \in \{1, \dots, n\}$. Si un vector x es no negativo escribiremos $x \geq 0$.

Al hilo de esta definición, vamos a generalizar ese concepto que lleva presente en nuestras vidas desde que aquel docente de primaria nos dibujó dos rectas perpendiculares en la pizarra, los cuadrantes.

Definición 1.1.2 (2^n -ante positivo). Definimos el 2^n -**ante positivo** de \mathbb{R}^n como el conjunto de los vectores no negativos de \mathbb{R}^n .

Se deja como ejercicio al lector justificar el nombre de 2^n -ante.

Dicho esto, ya podemos formular el problema de la programación lineal.

Problema 1.1 (Formulación general). La disciplina de la **programación lineal** estudia procedimientos (implementables en ordenador) para calcular los extremos absolutos de una aplicación lineal $f : \mathbb{R}^n \rightarrow \mathbb{R}$ cuando restringimos su dominio a una variedad afín de \mathbb{R}^n cortada con el 2^n -ante positivo.



Figura 1.1: Ilustración del problema de programación lineal.

En el caso de la ilustración 1.1 suponemos que f es una aplicación lineal definida sobre todo el plano a la cual restringimos el dominio a la variedad afín \mathcal{L} cortada con el cuadrante positivo (línea azul). Nuestro deber es encontrar los puntos (si los hay) sobre la línea azul en los cuales f alcanza un máximo o un mínimo absoluto.

En esta sección nos dedicaremos simplemente a formular de diversas maneras el problema de la programación lineal, observando que todas son equivalentes entre sí. Comencemos pues, sin más dilación nuestro viaje por lo desconocido, un viaje del que probablemente no regresaremos.

A continuación vemos una sencilla caracterización de las aplicaciones lineales $f : \mathbb{R}^n \rightarrow \mathbb{R}$ a partir de su expresión analítica.

Observación 1.1.1 (Expresión analítica). Consideremos una aplicación lineal $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Por ser f una aplicación lineal, tendrá una única matriz asociada C . Como salta a la vista, C será una matriz fila con n columnas.

Entonces, dado un vector $x \in \mathbb{R}^n$ se tiene que

$$f(x) = f(x_1, \dots, x_n) = CX = (c_1 \quad \cdots \quad c_n) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = c_1x_1 + \cdots + c_nx_n \quad (1.1)$$

De esta forma se concluye que toda aplicación lineal $f : \mathbb{R}^n \rightarrow \mathbb{R}$ tiene una expresión analítica de la forma de la ecuación (1.1). Recíprocamente, toda función $g : \mathbb{R}^n \rightarrow \mathbb{R}$ con una expresión analítica como la de (1.1) es una ecuación lineal, para demostrarlo, basta con leer como los árabes la ecuación (1.1). \diamond

Antes de continuar es importante hacer un inciso acerca de la notación.

Observación 1.1.2 (Notación matricial). Siempre que escribamos matrices fila o columna lo haremos con letras minúsculas. Asimismo, siempre que estemos escribiendo una matriz fila añadiremos el símbolo de trasposición, para dejarlo claro implícitamente. De esta manera, a las funciones lineales las denotaremos por

$$f(x_1, \dots, x_n) = c^t x$$

donde c^t es la matriz asociada a f y x es el vector columna con las coordenadas de x respecto de la base canónica (nótese el pequeño abuso de notación). \diamond

1.1.1. Forma estándar y formas canónicas

Sea $f(x_1, \dots, x_n) = c_1x_1 + \cdots + c_nx_n = c^t x$ una función lineal a la que a partir de ahora llamaremos **función objetivo**. A la matriz c se la denomina **vector de coeficientes de la función objetivo**, mientras que x recibe el nombre de **vector de variables de decisión**.

Consideremos asimismo la variedad afín de \mathbb{R}^n dada por el conjunto de soluciones al sistema no necesariamente homogéneo $Ax = b$. Escrito de forma desarrollada

$$\begin{cases} a_{11}x_1 + \cdots + a_{1n}x_n = b_1 \\ \vdots & \ddots & \vdots & \vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n = b_m \end{cases} \quad \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

A la matriz $A \in \mathfrak{M}_{m \times n}(\mathbb{R})$ usualmente la llamaremos **matriz de coeficientes de las restricciones**, además, a cada una de las ecuaciones del sistema las llamaremos **restricciones**. Asimismo, el vector b será conocido como **vector de términos independientes**.

Expongamos ahora la llamada “*formulación estándar*” del problema de la programación lineal.

Problema 1.2 (Forma estándar). El problema de programación lineal en **forma estándar** consiste en hallar los vectores $x \geq 0$ tales que sean solución de $Ax = b$ y además sean mínimos absolutos de la función f . Usualmente se escribe de forma sintética (aunque no lo usaremos mucho)

$$\begin{array}{ll} \text{mín } c^t x \\ \text{Sujeto a:} & Ax = b, \quad x \geq 0 \end{array}$$

Nótese que la formulación del problema en forma estándar es exactamente la misma que la formulación general 1.1 con la única diferencia de que ya no buscamos extremos absolutos en general, sino únicamente mínimos.

La formulación estándar del problema de programación lineal puede parecer muy inflexible, en el sentido de que, a simple vista, no parece ser demasiado útil para modelizar problemas reales. Es esta aparente rigidez la que lleva a plantearse otras formulaciones más laxas del problema de programación lineal. Las llamadas “*formulaciones canónicas*” que exponemos a continuación.

Problema 1.3 (Primera forma canónica). Esta nueva formulación a la que llamamos *primera forma canónica* plantea el problema de hallar los vectores $x \geq 0$ tales que satisfagan la ecuación $Ax \leq b$ y que además sean máximos absolutos de la función objetivo f . Escrito de forma compacta

$$\begin{array}{ll} \text{máx } c^t x \\ \text{Sujeto a:} & Ax \leq b, \quad x \geq 0 \end{array}$$

Problema 1.4 (Segunda forma canónica). El problema de programación lineal en *segunda forma canónica* consiste en encontrar los vectores $x \geq 0$ tales que satisfagan la ecuación $Ax \geq b$ y que además sean mínimos absolutos de la función objetivo f . En resumen

$$\begin{array}{ll} \text{mín } c^t x \\ \text{Sujeto a:} & Ax \geq b, \quad x \geq 0 \end{array}$$

Una vez vistas todas las formulaciones, hagamos una pequeña reflexión. Sería la apoteosis del tedio tener que demostrar resultados teóricos para cada una de las formulaciones. No obstante, no hay que dejar nunca de confiar en los dioses olímpicos, pues a veces son benévolo con nosotros. Esta benevolencia consiste en que todas las formulaciones son equivalentes en el sentido que veremos a continuación.

Maximización y minimización

Si se nos plantea el problema de hallar el máximo absoluto de una función objetivo f podemos transformar este problema en uno equivalente de forma que el objetivo de el nuevo problema sea hallar el mínimo de otra función objetivo g .

La utilidad de este hecho es que podemos transformar un problema de programación lineal en primera forma canónica (que surgen de forma natural a la hora de modelizar problemas reales) en un problema más parecido a la formulación estándar.

Lema 1.1.1 (Maximización–minimización). Sea A un conjunto arbitrario y una función $f : A \rightarrow \mathbb{R}$ que alcanza el máximo y el mínimo. Entonces se cumple

$$\text{máx } f = -\text{mín}(-f)$$

Demostración. Sea ξ el máximo de f , es decir, el único número de $f(A)$ que verifica que $f(x) \leq \xi$ para todo $x \in A$. Consideremos ahora la función $g \equiv -f$, que, por las propiedades de los números reales alcanza el mínimo, al que llamaremos η .

Evidentemente η verifica que $g(x) \geq \eta$ para todo $x \in A$, o equivalentemente $-g(x) \leq -\eta$ para todo $x \in A$. Pero $-g(x) = f(x)$, luego $f(x) \leq -\eta$ para todo $x \in A$. Por unicidad del máximo $-\eta = \xi$, como queríamos demostrar. ■

Observación 1.1.3 (Aplicación). Si tenemos un problema de programación lineal formulado en términos de maximización bastará con cambiar la función objetivo f por la función objetivo $-f$ para obtener un problema equivalente en términos de minimización.

Para obtener las soluciones del primer problema en términos del segundo bastará con cambiar el valor por la función objetivo de las soluciones del segundo problema por su opuesto. ◇

Igualdades y desigualdades

Una vez visto el apartado anterior, vamos a aprender a transformar restricciones de tipo desigualdad a restricciones de tipo igualdad, con lo cual ya podremos transformar cualquier problema planteado en alguna forma canónica a un problema equivalente planteado en forma estándar.

Lema 1.1.2 (Variables de holgura). *Sea una restricción de la forma*

$$a_{i1}x_1 + \cdots + a_{in}x_n \stackrel{(\geq)}{\leq} b_i \quad (1.2)$$

entonces la restricción

$$a_{i1}x_1 + \cdots + a_{in}x_n + x_i^h \stackrel{(-)}{=} b_i \quad (1.3)$$

*es equivalente, en el sentido de que hay una biyección “natural” entre los conjuntos de vectores **no negativos** que verifican cada una de las restricciones.*

*A la variable x_i^h añadida en la restricción (1.3) se la denomina **variable de holgura**.*

Demostración. Sean los conjuntos \mathcal{S} y \mathcal{S}' de vectores que verifican las restricciones (1.2) y (1.3) respectivamente. Consideremos la aplicación

$$\begin{aligned} \varphi : \quad \mathcal{S} &\rightarrow \mathcal{S}' \\ (x_1, \dots, x_n) &\mapsto (x_1, \dots, x_n, z) \end{aligned}$$

donde $z = b_i - a_{i1}x_1 - \cdots - a_{in}x_n$. Veamos que es una biyección.

La inyectividad es clara por definición, si dos vectores compartieran imagen todas sus componentes coinciden.

En cuanto a la sobreyectividad, dado un vector $(x_1, \dots, x_n, x_{n+1})$ que verifica la restricción (1.3), es claro que el vector resultante de eliminar la última componente, (x_1, \dots, x_n) , cumple la restricción (1.2).

La demostración para el caso \geq es totalmente simétrica. ■

Veamos que utilidad tiene lo que acabamos de demostrar.

Observación 1.1.4 (Aplicación). Si a la hora de modelizar un problema nos aparecen restricciones de tipo \geq o \leq basta con sustituirlas por restricciones equivalentes añadiendo variables de holgura.

Además, debemos cambiar la función objetivo f , extendiéndola de la siguiente manera

$$\begin{aligned} \widehat{f} : \quad \mathbb{R}^{n+m} &\rightarrow \mathbb{R} \\ (x_1, \dots, x_n, x_{n+1}, \dots, x_{n+m}) &\mapsto f(x_1, \dots, x_n) \end{aligned}$$

donde n es el número total de restricciones originales y m el número de restricciones de tipo desigualdad.

Para obtener las soluciones del problema original en términos de este nuevo problema equivalente basta con quitar las componentes correspondientes a las variables de holgura. ◇

Con lo que sabemos hasta el momento podemos transformar cualquier problema escrito en cualquiera de las formas canónicas en un problema en forma estándar.

Positividad y negatividad

Otro caso que se presenta de manera usual es que al modelizar un problema concreto sea necesario permitir que algunas componentes de los vectores candidatos a ser solución sean negativas. Esta es una situación que no contempla la formulación estándar, sin embargo, con un simple truco podemos meter esta clase de problemas dentro de nuestro marco de actuación.

Observación 1.1.5 (Truco). Si tenemos un problema en el que la componente i -ésima de los vectores puede ser negativa tomamos todas las restricciones

$$a_{j1}x_1 + \cdots + a_{ji}x_i + \cdots + a_{jn}x_n = b_j$$

que involucren a la componente x_i y las sustituimos por las restricciones

$$a_{j1}x_1 + \cdots + a_{ji}(x_i^+ - x_i^-) + \cdots + a_{jn}x_n = b_j$$

con x_i^+ y x_i^- no negativos.

Es claro que si un vector $(x_1, \dots, x_i, \dots, x_n)$ (donde x_i es negativo) verifica las restricciones originales, entonces el vector $(x_1, \dots, 0, -x_i, \dots, x_n)$ (por ejemplo) verifica las restricciones nuevas. Análogamente si x_i es positivo. Asimismo, si el vector $(x_1, \dots, x_i^+, x_i^-, \dots, x_n)$ cumple las restricciones nuevas, el vector $(x_1, \dots, x_i^+ - x_i^-, \dots, x_n)$ cumplirá las viejas, pudiendo concluir así que las restricciones viejas y nuevas son equivalentes en un sentido un poco más laxo que en el apartado anterior, ya que únicamente se tiene la sobreyectividad (pero esto es irrelevante).

De esta forma, si cambiamos la función objetivo f por la función

$$\begin{aligned} \bar{f} : \quad & \mathbb{R}^{n+1} \rightarrow \mathbb{R} \\ (x_1, \dots, x_i^+, x_i^-, \dots, x_n) & \mapsto f(x_1, \dots, x_i^+ - x_i^-, \dots, x_n) \end{aligned}$$

obtenemos un problema equivalente.

Para obtener la solución del problema original en términos de este nuevo problema basta considerar el vector $(x_1, \dots, x_i^+ - x_i^-, \dots, x_n)$ donde $(x_1, \dots, x_i^+, x_i^-, \dots, x_n)$ es el vector solución del problema con las restricciones nuevas. \diamond

Hechas todas estas disquisiciones iniciales cabe mencionar que a la hora de modelizar problemas, siempre que tanto la función objetivo como las restricciones sean lineales, podremos realizar transformaciones (las vistas en esta sección) para que el problema quede planteado en forma estándar, pudiendo ser así resuelto mediante el uso de toda la artillería teórica que veremos a continuación.

1.1.2. Terminología y casuística

Dado un problema de programación lineal en forma estándar que tiene a A como matriz de coeficientes de las restricciones y a b como vector de términos independientes. Exponemos las siguientes definiciones.

Definición 1.1.3 (Soluciones). Llamamos **solución** del problema P a cualquier vector $x \in \mathbb{R}^n$ (no necesariamente no negativo) que verifique $Ax = b$.

Sacando un poco de punta al asunto, diremos que si $x \in \mathbb{R}^n$ es solución del problema y además $x \geq 0$ entonces x es una **solución factible**.

Llamaremos **región factible** al conjunto de todas las soluciones factibles del problema. Normalmente la denotaremos con la letra \mathcal{S} .

Una vez resuelto el problema se pueden dar las siguientes situaciones

- La región factible posee al menos un punto en el cual la función objetivo alcanza el mínimo. En esta situación diremos que el problema posee **solución óptima**.
- La región factible del problema es el conjunto vacío. En este caso se dirá que el problema es **infactible**.
- La función objetivo alcanza valores tan bajos como queramos en la región factible. En este caso se dice que el problema posee una solución **no acotada**.

A lo largo del capítulo veremos por qué no se puede dar ninguna otra situación.

Teniendo en cuenta estas pequeñas observaciones podemos empezar a estudiar cómo son las regiones factibles, lo cual nos será muy útil para resolver el problema de programación lineal.

1.2. Programación lineal y conjuntos convexos

En esta sección demostraremos que las regiones factibles de un problema de programación lineal en forma estándar son siempre conjuntos convexos.

Asimismo, estudiaremos en profundidad las propiedades de estos conjuntos, explotándolas para obtener un procedimiento robusto con el cual resolver estos problemas.

1.2.1. Conjuntos convexos. Definición y propiedades

Comenzamos definiendo el concepto de conjunto convexo.

Definición 1.2.1 (Convexos). Sea \mathcal{S} un subconjunto de \mathbb{R}^n , se dice **convexo** si para cada par de puntos $x, y \in \mathcal{S}$ el segmento que tiene por extremos a x e y está contenido en \mathcal{S} . Es decir

$$\lambda x + (1 - \lambda)y \in \mathcal{S}$$

para todo $\lambda \in [0, 1]$. Nótese que el conjunto vacío se considera convexo.

La región factible de un problema de programación lineal en forma estándar es un conjunto convexo.

Lema 1.2.1 (Región convexa). *El conjunto de los vectores no negativos $x \in \mathbb{R}^n$ que verifican la condición $Ax = b$ para cierta matriz A y cierto vector b es un conjunto convexo.*

Demostración. Si la región factible \mathcal{S} es el conjunto vacío ya hemos terminado. En otro caso, basta considerar dos vectores x e y de la región factible y ver que $\alpha x + (1 - \alpha)y \in \mathcal{S}$ para todo $\alpha \in [0, 1]$, pero esto es inmediato ya que

$$A(\alpha x + (1 - \alpha)y) = \alpha Ax + (1 - \alpha)Ay = \alpha b + (1 - \alpha)b = b \quad \blacksquare$$

Una cuestión importante a destacar es que la intersección arbitraria de conjuntos convexos es convexo, tal y como muestra el siguiente lema.

Lema 1.2.2 (Intersección). *Sea \mathcal{F} una familia de conjuntos convexos. La intersección de la familia es un conjunto convexo.*

Demostración. Sean x e y dos puntos de la intersección de la familia, luego x e y están en todos los conjuntos de la familia. Como estos conjuntos son convexos, el segmento que une x e y estará contenido en todos los conjuntos de la familia simultáneamente, luego también en la intersección de la familia. \blacksquare

Un concepto por el que merece la pena pasar es el de “envoltura convexa” de un conjunto \mathcal{S} de \mathbb{R}^n , que viene a ser el menor conjunto convexo que contiene a \mathcal{S} .

Esta idea es especialmente recurrente en las matemáticas, por ejemplo, en álgebra lineal teníamos el subespacio generado por un subconjunto, en teoría de grupos el subgrupo generado por un subconjunto, en topología tenemos la adherencia de un conjunto, . . . La lista es interminable.

Observación 1.2.1 (Justificación). Es fácil darse cuenta de que, como la intersección arbitraria de convexos es convexa, el menor conjunto convexo que contiene a uno dado (al que llamaremos \mathcal{S}) puede ser construido de la siguiente manera

$$\text{Conv}(\mathcal{S}) := \bigcap_{\mathcal{F} \supset \mathcal{S}} \mathcal{F}$$

En efecto, es un conjunto que contiene a \mathcal{S} , ya que todos los conjuntos de la familia a intersecar contienen a \mathcal{S} , además, es el menor de ellos, ya que, de haber uno más pequeño, pertenecería a la familia que se está intersecando, lo cual es absurdo (¡compruébese!).

De esta forma queda justificada la existencia del menor conjunto convexo que contiene a \mathcal{S} , no obstante, la construcción que hemos realizado nos da escasa información acerca de los elementos de la envoltura convexa. \diamond

Observación 1.2.2 (Curiosidad). A modo de curiosidad comentamos que el problema de calcular la envoltura convexa de un conjunto finito de n puntos en el plano o el espacio es uno de los problemas centrales de la **geometría computacional** por sus múltiples aplicaciones. \diamond

Veamos a continuación una caracterización útil de la envoltura convexa de un conjunto, para la cual necesitamos introducir una definición.

Definición 1.2.2 (Combinaciones convexas). Sea $\{z_1, \dots, z_r\}$ un conjunto finito de puntos. Diremos que z es **combinación lineal convexa** de dichos puntos si

$$z = \lambda_1 z_1 + \dots + \lambda_r z_r$$

donde $\lambda_i > 0$ para $i \in \{1, \dots, r\}$ y se cumple que $\sum_{i=1}^r \lambda_i = 1$.

Que no asuste la longitud de la demostración de la proposición pues realmente es muy sencilla.

Proposición 1.2.3 (Caracterización). *Dado un conjunto \mathcal{S} , su envoltura convexa es el conjunto de puntos que son una combinación lineal convexa de puntos de \mathcal{S} .*

Demostración. Llamemos $\mathcal{H}(\mathcal{S})$ al conjunto de puntos que son combinación lineal convexa de puntos de \mathcal{S} . Veamos en primer lugar que $\mathcal{H}(\mathcal{S})$ contiene a \mathcal{S} . Esto es claro, ya que todo punto x de \mathcal{S} es combinación lineal convexa de puntos de \mathcal{S} , en efecto, $x = 1 \cdot x$.

Veamos ahora que $\mathcal{H}(\mathcal{S})$ es convexo. Esto lo haremos simplemente usando la definición. Sean x e y dos puntos de $\mathcal{H}(\mathcal{S})$, veamos que $\alpha x + (1 - \alpha)y \in \mathcal{H}(\mathcal{S})$ para todo $\alpha \in [0, 1]$.

Por definición de $\mathcal{H}(\mathcal{S})$

$$x = \sum_{i=1}^r \lambda_i x_i \quad y = \sum_{j=1}^s \mu_j y_j$$

por tanto, si sustituimos esto en $\alpha x + (1 - \alpha)y$ obtenemos

$$\alpha x + (1 - \alpha)y = \sum_{i=1}^r (\alpha \lambda_i) x_i + \sum_{j=1}^s [(1 - \alpha) \mu_j] y_j$$

Haciendo los siguientes cambios de nombre

$$\xi_k := \begin{cases} \alpha \lambda_k & \text{si } k \in \{1, \dots, r\} \\ (1 - \alpha) \mu_{k-r} & \text{si } k \in \{r+1, \dots, r+s\} \end{cases} \quad z_k := \begin{cases} x_k & \text{si } k \in \{1, \dots, r\} \\ y_{k-r} & \text{si } k \in \{r+1, \dots, r+s\} \end{cases}$$

nos queda que

$$\alpha x + (1 - \alpha)y = \sum_{k=1}^{r+s} \xi_k z_k$$

luego por definición de $\mathcal{H}(\mathcal{S})$ solo queda comprobar que $\sum_{k=1}^{r+s} \xi_k = 1$, pero esto es evidente ya que

$$\sum_{k=1}^{r+s} \xi_k = \alpha \sum_{i=1}^r \lambda_i + (1 - \alpha) \sum_{j=1}^s \mu_j = \alpha + (1 - \alpha) = 1$$

Queda por ver pues que $\mathcal{H}(\mathcal{S})$ es el menor conjunto convexo que contiene a \mathcal{S} . Para ello, consideramos \mathcal{C} un conjunto convexo arbitrario que contiene a \mathcal{S} . Demostremos que $\mathcal{H}(\mathcal{S}) \subset \mathcal{C}$ por inducción sobre la “longitud” de la combinación lineal convexa de sus elementos.

El caso base es evidente, ya que los elementos de $\mathcal{H}(\mathcal{S})$ que son combinaciones lineales convexas de longitud unitaria son también elementos de \mathcal{S} y por tanto de \mathcal{C} . Supongamos cierto que los elementos de $\mathcal{H}(\mathcal{S})$ que son combinaciones lineales convexas de longitud n viven también en \mathcal{C} , y demostremos que lo mismo sucederá para los elementos que sean combinaciones de longitud $n+1$.

Consideremos $z \in \mathcal{H}(\mathcal{S})$ un elemento que es combinación de longitud $n+1$, es decir

$$z = \sum_{i=1}^{n+1} \lambda_i z_i \quad \text{con} \quad \sum_{i=1}^{n+1} \lambda_i = 1$$

Vamos a apañar la expresión de z para poder aplicar la hipótesis de inducción

$$z = \sum_{i=1}^n \lambda_i z_i + \lambda_{n+1} z_{n+1}$$

Es claro que $z_{n+1} \in \mathcal{C}$ por ser una combinación de longitud uno. Sin embargo, el primer sumando no es una combinación lineal convexa ya que $\sum_{i=1}^n \lambda_i = 1 - \lambda_{n+1} \neq 1$. Para arreglar esto vamos a multiplicar y a dividir el primer sumando por $1 - \lambda_{n+1}$

$$z = (1 - \lambda_{n+1}) \sum_{i=1}^n \frac{\lambda_i}{1 - \lambda_{n+1}} z_i + \lambda_{n+1} z_{n+1}$$

De esta forma el primer sumando (excluyendo el factor que lo multiplica) es una combinación lineal convexa de longitud n , ya que $\frac{1}{1 - \lambda_{n+1}} \sum_{i=1}^n \lambda_i = \frac{1 - \lambda_{n+1}}{1 - \lambda_{n+1}} = 1$.

Por hipótesis de inducción, tanto el primer sumando como el segundo (excluyendo los factores que los multiplican) son elementos de \mathcal{C} , y como \mathcal{C} es convexo $z \in \mathcal{C}$, como queríamos. ■

1.2.2. Puntos extremos

De ahora en adelante será de utilidad tener en mente un polígono regular cuando se nos hable de conjuntos convexos, pues nos dará una idea bastante intuitiva.

Para estrenar esta nueva buena costumbre se presenta la siguiente definición.

Definición 1.2.3 (Punto extremo). Sea \mathcal{C} un conjunto convexo. Diremos que $\bar{x} \in \mathcal{C}$ es un **punto extremo** de \mathcal{C} si se verifica que para cualquier par de puntos $x_1, x_2 \in \mathcal{C}$, \bar{x} **no** está en el segmento generado por dichos puntos (excluyendo los extremos). Es decir

$$\bar{x} = \lambda x_1 + (1 - \lambda) x_2 \iff \begin{cases} \lambda \in \{0, 1\} \\ x_1 = x_2 \end{cases}$$

La ilustración 1.2 marca en negro los puntos extremos de un polígono regular, para coger una idea intuitiva. A lo largo de este capítulo veremos la importancia que tienen estos puntos en la resolución del problema de programación lineal. El teorema 1.2.4 nos da una caracterización de los




Figura 1.2: Ilustración de los puntos extremos de un heptágono regular.

puntos extremos de una región factible que, aunque muy potente, resulta poco intuitiva. Antes de enunciarlo recordemos un viejo resultado de álgebra lineal.

Observación 1.2.3 (Rango y submatrices). Es conocido desde tiempos inmemoriales que $A \in \mathfrak{M}_{m \times n}(\mathbb{K})$ con $m \leq n$ y $\text{rg}(A) = m$ entonces habrá al menos una submatriz cuadrada $B \in \mathfrak{M}_m(\mathbb{K})$ de A tal que $\text{rg}(B) = m$. De esta forma, reordenando las columnas de A si fuera necesario, podemos hacer la siguiente división por bloques de A .

$$A = (B|N)$$

Nótese que la igualdad se da solo cuando ya hemos reordenado A . ◇

A partir de ahora trabajaremos con matrices en las condiciones de la observación 1.2.3 a no ser que se especifique lo contrario. Nótese que esto no supone ninguna pérdida de generalidad en lo que se refiere al estudio de los problemas de programación lineal ya que si se nos presentara una matriz con más filas que columnas habrá restricciones redundantes.

Definición 1.2.4 (Bases). Dado un problema en forma estándar que tiene a A por matriz de coeficientes de las restricciones, llamaremos **base** de A a toda submatriz suya cuadrada y de rango máximo.

Teorema 1.2.4 (Caracterización). *Dada una región factible \mathcal{S} , \bar{x} es un punto extremo de \mathcal{S} si y solo si hay alguna reordenación de las columnas de A de forma que*

$$A = (B|N) \quad \bar{x} = \begin{pmatrix} \bar{x}_B \\ \bar{x}_N \end{pmatrix} \text{ con } \bar{x}_N = 0$$

donde B es una base de A y \bar{x}_B y \bar{x}_N son los “trozos” de \bar{x} acordes con la descomposición en bloques de A , es decir

$$A\bar{x} = (B|N) \begin{pmatrix} \bar{x}_B \\ \bar{x}_N \end{pmatrix} = B\bar{x}_B + N\bar{x}_N$$

Demostración. Veamos las dos implicaciones

\Leftarrow Supongamos que \bar{x} no es punto extremo, entonces habrá dos puntos distintos $x_1, x_2 \in \mathcal{S}$ tales que $\bar{x} = \lambda x_1 + (1 - \lambda)x_2$ con $\lambda \in (0, 1)$. Desplegando la descomposición por bloques tendríamos que

$$(\bar{x}_B|\bar{x}_N)^t = \lambda(x_B^1|x_N^1)^t + (1 - \lambda)(x_B^2|x_N^2)^t$$

Como por hipótesis $\bar{x}_N = 0$ y tanto λ como $1 - \lambda$ son estrictamente positivos se tiene que $x_N^1 = x_N^2 = 0$, ya que x_1 y x_2 deben ser no negativos.

Como $x_1, x_2 \in \mathcal{S}$, entonces $Ax_i = b$ para $i \in \{1, 2\}$, por tanto

$$(B|N)(x_B^i|x_N^i)^t = (B|N)(x_B^i|0)^t = Bx_B^i = b \implies x_B^i = B^{-1}b$$

Con lo que se concluye que $x_1 = x_2$, lo cual es absurdo.

\Rightarrow Sea \bar{x} un punto extremo. Reordenemos el vector de forma que todas sus componentes nulas queden al final, reordenando solidariamente las columnas de la matriz A .

Podemos suponer pues que el vector \bar{x} tiene $p \neq 0$ componentes no nulas (si $p = 0$ el resultado es evidente). Vamos a demostrar que las p primeras columnas de A (ya reordenada) son linealmente independientes.

A partir de ahora denotaremos a la matriz A por sus columnas, es decir $A = (a_1 \cdots a_n)$ donde a_i representa la i -ésima columna de A .

Procedamos por reducción al absurdo, es decir, supongamos que hay ciertos números reales no todos nulos λ_i tales que $\sum_{i=1}^p \lambda_i a_i = 0$.

Definimos el vector $\lambda := (\lambda_1, \dots, \lambda_p, 0, \dots, 0) \in \mathbb{R}^n$. A continuación consideramos los vectores **no negativos** $x_1 := \bar{x} + \alpha\lambda$ y $x_2 := \bar{x} - \alpha\lambda$ tomando un α lo suficientemente pequeño para que ambos vectores sean precisamente no negativos, lo cual siempre puede hacerse al ser \bar{x} no negativo.

Los vectores x_1 y x_2 tienen la particularidad de que con ellos podemos obtener \bar{x} como combinación lineal convexa. En efecto $\bar{x} = \frac{1}{2}x_1 + \frac{1}{2}x_2$. Si resultara que x_1 y x_2 son puntos de la región factible estaríamos entrando en contradicción con la “extremalidad” de \bar{x} , y eso es exactamente lo que vamos a hacer. En efecto, con $i \in \{1, 2\}$ tenemos

$$Ax_i = A\bar{x} \pm \alpha A\lambda \stackrel{!}{=} A\bar{x} = b \implies x_i \in \mathcal{S}$$

donde la igualdad de la exclamación se debe a la composición de λ y la dependencia lineal de las p primeras columnas de A (por hipótesis). Con esto llegamos a un absurdo y concluimos que las p primeras columnas de A son linealmente independientes.

Además, de paso podemos concluir que $p \leq m$, ya que m es el rango máximo de A . Si además $p = m$ ya tenemos una base $B = (a_1 \cdots a_p)$ que cumple lo que queremos (¡compruébese!). En el caso de que $p < m$ la observación 1.2.3 nos dice que siempre podemos escoger columnas adicionales de A para completar una base y, tras una nueva reordenación de A si fuera necesario tendríamos lo que necesitamos. ■

Corolario 1.2.5 (Parte básica). *Dado un punto extremo $\bar{x} = (\bar{x}_B|0)^t$ de una región factible \mathcal{S} se cumple que $\bar{x}_B = B^{-1}b$.*

Demostración. Basta con echar las cuentas. Como $\bar{x} \in \mathcal{S}$ es claro que $A\bar{x} = b$, luego

$$A\bar{x} = (B|N)(\bar{x}_B|0)^t = B\bar{x}_B = b$$

y despejando se tiene que $\bar{x}_B = B^{-1}b$. ■

Al hilo de este teorema surge la siguiente definición.

Definición 1.2.5 (Soluciones básicas). A los puntos extremos de una región factible se les suele llamar ***soluciones básicas factibles***. Esto es debido a que, por el teorema 1.2.4, están “asociados” a una base de la matriz asociada a la región factible del problema.

Observación 1.2.4 (Procedimiento constructivo). Nótese que si nos dan un punto extremo de una región factible y nos piden hallar la base asociada a dicho punto extremo no tenemos más que seguir la demostración de la implicación a la derecha del teorema 1.2.4 para encontrarla, es decir, tomar las columnas de A asociadas a las componentes no nulas del punto extremo y, en su caso, completar la base.

Esto nos lleva a deducir de forma evidente que cada punto extremo puede estar asociado a más de una base (salvo reordenaciones). ◇

Una de las razones por la cual es estudio de los puntos extremos es importante es porque toda región factible de un problema de programación lineal en forma estándar tiene al menos un punto extremo, y además únicamente tiene una cantidad finita de ellos.

Observación 1.2.5 (Finitud). Una región factible tiene un número finito de puntos extremos, esto es debido a que A tiene más bases que puntos extremos, ya que cada base B está asociada a un único candidato a punto extremo, el punto que tiene a $B^{-1}b$ como parte básica. Además, cada matriz tiene a lo sumo $\binom{n}{m}$ bases. ◇

Teorema 1.2.6 (Existencia). *Toda región factible no vacía posee al menos un punto extremo.*

Demostración. Sea \bar{x} un punto arbitrario de la región factible. Reordenemos sus componentes de forma que las componentes nulas queden al final, asimismo reordenemos A de forma coherente con la reordenación de \bar{x} . Supongamos que \bar{x} posee p componentes no nulas (las p primeras tras la reordenación).

Ahora consideramos las columnas de A correspondientes a las p componentes no nulas de \bar{x} . Si estas columnas son linealmente independientes, por el teorema 1.2.4 habríamos terminado.

Si, por el contrario, las columnas (que serán las p primeras tras la reordenación) son linealmente dependientes, entonces existirán ciertos números reales λ_i no todos nulos tales que $\sum_{i=1}^p \lambda_i a_i = 0$, donde a_i representa a la i -ésima columna de A .

Lo que vamos a hacer es cambiar ligeramente el punto \bar{x} de forma que siga siendo de la región factible y conserve un subconjunto estrictamente menor de las componentes no nulas de \bar{x} .

En primer lugar cabe mencionar que siempre podemos suponer que existe al menos un $r \in \{1, \dots, p\}$ de forma que $\lambda_r > 0$, ya que en caso de que todos los números de la combinación lineal fueran negativos podemos considerar la combinación lineal alternativa $\sum_{i=1}^p -\lambda_i a_i = 0$, en la cual todos los escalares son positivos.

Definimos ahora el vector $\lambda := (\lambda_1, \dots, \lambda_p, 0, \dots, 0) \in \mathbb{R}^n$ y consideramos el puntos $\bar{x}' := \bar{x} - \alpha\lambda$ para cierto $\alpha > 0$ que definiremos más adelante.

El punto \bar{x}' verifica la condición $Ax = b$, en efecto

$$A\bar{x}' = A\bar{x} - \alpha A\lambda = A\bar{x} = b$$

Luego únicamente queda elegir un α adecuado para que $\bar{x}' \geq 0$. Para ello elegiremos

$$\alpha := \min \left\{ \frac{\bar{x}_j}{\lambda_j} : \lambda_j > 0 \right\} = \frac{\bar{x}_l}{\lambda_l}$$

Veamos que \bar{x}' es no negativo. Para ello distinguiremos casos componente a componente.

- Si $\lambda_j > 0$ tenemos que $\bar{x}'_j = \bar{x}_j - \frac{\bar{x}_l}{\lambda_l} \lambda_j = \frac{\bar{x}_j}{\lambda_j} \lambda_j - \frac{\bar{x}_l}{\lambda_l} \lambda_j = \lambda_j \left(\frac{\bar{x}_j}{\lambda_j} - \frac{\bar{x}_l}{\lambda_l} \right)$ y este número es no negativo por definición de α .

- Si $\lambda_j \leq 0$ evidentemente $\bar{x}'_j = \bar{x}_j - \alpha\lambda_j$ es no negativo por ser la suma de números no negativos.

Cabe destacar que si $\bar{x}_j = 0$ entonces $\bar{x}'_j = 0$, además $\bar{x}_l > 0$ mientras que $\bar{x}'_l = 0$, luego \bar{x}' tiene a lo sumo $p-1$ componentes no nulas, con lo que, al volver al principio de la demostración el conjunto de columnas que queremos que sean linealmente independientes se ha visto reducido en una columna como poco. Por tanto, tras un número finito de pasos encontraremos un punto extremo. Esto proporciona un algoritmo para encontrar un punto extremo de una región factible. ■

Culminamos este teorema con una pequeña observación.

Observación 1.2.6 (Extremalidad del 0). Si una región factible contiene al vector 0, este es siempre un punto extremo, basta con aplicar el teorema 1.2.6 para comprobarlo (el conjunto vacío es linealmente independiente). ◇

El siguiente teorema termina de mostrar la brutal importancia de los puntos extremos de las regiones factibles en los problemas de programación lineal, y es que, si un problema tiene solución óptima, esta se alcanza en un punto extremo o solución básica factible.

Teorema 1.2.7 (Optimalidad). Si un problema de programación lineal en forma estándar tiene solución óptima, esta se alcanza en un punto extremo.

Demostración. Procedemos de análogamente a como hicimos en la demostración del teorema 1.2.6.

Consideremos \bar{x} un punto donde se alcanza la solución óptima al problema en cuestión. Reordenemos las coordenadas de \bar{x} dejando las componentes nulas al final, reordenando también A solidariamente.

Suponiendo que \bar{x} tiene p componentes no nulas y que las columnas de A correspondientes a dichas columnas son linealmente dependientes (en caso contrario hemos terminado), entonces habrá ciertos números reales no todos nulos (de hecho podemos suponer que alguno será positivo) tales que $\sum_{i=1}^n \lambda_i a_i = 0$. Definimos el vector $\lambda \in \mathbb{R}^n$ de la manera usual y consideramos los puntos

$$x_1 = \bar{x} + \alpha_1 \lambda \quad x_2 = \bar{x} - \alpha_2 \lambda$$

siendo α_1 y α_2 coeficientes positivos lo suficientemente pequeños para que x_1 y x_2 sean no negativos.

Es evidente que tanto x_1 como x_2 cumplen la condición $Ax = b$, esto se debe a la dependencia lineal de las p primeras columnas y a la definición de λ , como ya hemos hecho en otras ocasiones.

Evaluemos los puntos x_1 y x_2 por la función objetivo

$$\begin{aligned} c^t x_1 &= c^t \bar{x} + \alpha_1 c^t \lambda \\ c^t x_2 &= c^t \bar{x} - \alpha_2 c^t \lambda \end{aligned}$$

Por la optimalidad de \bar{x} se tiene que

$$c^t \bar{x} \leq c^t \bar{x} + \alpha_1 c^t \lambda \quad (1.4)$$

$$c^t \bar{x} \leq c^t \bar{x} - \alpha_2 c^t \lambda \quad (1.5)$$

De la ecuación (1.4) se deduce que $c^t \lambda \geq 0$ y de la ecuación (1.5) se desprende que $c^t \lambda \leq 0$, luego $c^t \lambda = 0$, por tanto tanto x_1 como x_2 son puntos en los que también se alcanza la solución óptima. Centrémonos en x_2 . Si tomamos α_2 como

$$\alpha_2 := \min \left\{ \frac{\bar{x}_j}{\lambda_j} : \lambda_j > 0 \right\}$$

sabemos que x_2 sigue perteneciendo a la región factible (como demostramos en el teorema 1.2.6) luego es una elección válida. Además, por las mismas razones que en el teorema 1.2.6, el vector x_2 tiene a lo sumo $p-1$ componentes positivas, luego, tras un número finito de pasos encontraremos un punto extremo en el cual se alcance la solución óptima. ■

1.2.3. Direcciones extremas

El siguiente es el último concepto relativo a convexidad que veremos, se trata del concepto de “dirección”. En palabras llanas podríamos decir que una “dirección” de un conjunto convexo es una flecha tal que si partimos de cualquier punto del conjunto y la seguimos nunca saldremos del conjunto. la siguiente definición formaliza este concepto.

Definición 1.2.6 (Dirección). Dado un conjunto convexo \mathcal{C} y un vector $d \in \mathbb{R}^n$ diremos que d es una **dirección** de \mathcal{C} si para todo punto $x \in \mathcal{C}$ se verifica que

$$x + \lambda d \in \mathcal{C}$$

para todo λ no negativo. Asimismo, dadas dos direcciones d_1 y d_2 diremos que son **equivalentes** si son vectores proporcionales.

Observación 1.2.7 (No acotación). Nótese que si un conjunto convexo es acotado no puede tener direcciones (compruébese). Luego cuando hablemos de direcciones será recomendable tener en mente conjuntos como el que representa la ilustración 1.3 (que continúa infinitamente hacia arriba y hacia la derecha). \diamond

Veamos a continuación un concepto análogo al de los puntos extremos pero en el ámbito de las direcciones.

Definición 1.2.7 (Dirección extrema). Sea d una dirección. Diremos que d es una **dirección extrema** si no puede escribirse como combinación lineal positiva de dos direcciones no equivalentes. De forma sintética

$$d = \lambda d_1 + \mu d_2 \text{ con } \lambda, \mu > 0 \iff d_1 \sim d_2$$

donde \sim denota la equivalencia de direcciones.




Figura 1.3: Ilustración de una dirección y una dirección extrema

Veamos una caracterización muy sencilla de las direcciones para regiones factibles.

Lema 1.2.8 (Caracterización débil). Dada una región factible \mathcal{S} , d es una dirección de \mathcal{S} si y solo si d es un vector no negativo y no nulo que verifica que $Ad = 0$.

Demostración. Veamos ambas implicaciones.

\Rightarrow Sea d una dirección, por tanto, dado $x \in \mathcal{S}$ y $\lambda \geq 0$ se cumple que $x + \lambda d \in \mathcal{S}$, luego $A(x + \lambda d) = b$, por tanto

$$A(x + \lambda d) = Ax + \lambda Ad = b + \lambda Ad = b \iff Ad = 0$$

Queda comprobar que d es un vector no negativo, para ello supongamos que tiene alguna componente negativa, digamos la i -ésima. Entonces por hipótesis $x_j + \lambda d_j \geq 0$ para todo $\lambda \geq 0$, sin embargo, tomando un λ lo suficientemente grande llegamos a un absurdo.

\Leftarrow Es claro que $x + \lambda d$ es un vector no negativo para todo $x \in \mathcal{S}$ (por hipótesis). Comprobemos que está en la región factible. En efecto

$$A(x + \lambda d) = Ax + \lambda Ad = Ax = b \quad \blacksquare$$

El lema anterior nos abre las puertas a una caracterización de las direcciones extremas mucho muy potente y extremadamente parecida al teorema 1.2.4, es decir, muy poco intuitiva. Conviene reflexionar sobre el enunciado antes de lanzarse a la demostración.

Teorema 1.2.9 (Caracterización fuerte). *Dada una región factible \mathcal{S} , d es una dirección extrema de \mathcal{S} si y solo si, tras una conveniente reordenación, hay una base B de A tal que*

$$A = (B|N) \quad d = \alpha \begin{pmatrix} -B^{-1}a_k \\ e_t \end{pmatrix}$$

donde a_k es una columna de N , o sea, la $k = m + t$ -ésima columna de A .

Además, $\alpha > 0$, $B^{-1}a_k \leq 0$ y e_t es el t -ésimo vector de la base canónica de \mathbb{R}^{n-m} .

Demostración. Veamos ambas implicaciones.

\Leftarrow Sea d un vector que cumple las propiedades del enunciado, luego no negativo y no nulo. Veamos en primer lugar que es una dirección de la región factible. En efecto, usando la única caracterización que tenemos

$$Ad = (B|N)(-B^{-1}a_k|e_t)^t = -BB^{-1}a_k + Ne_t = -a_k + a_k = 0$$

Para comprobar la extremalidad de d , supongamos que puede escribirse como combinación lineal positiva de dos direcciones d_1 y d_2 y veamos que estas direcciones son equivalentes.

Como $d = \lambda_1 d_1 + \lambda_2 d_2$, si nos fijamos únicamente en las $n - m$ últimas coordenadas se tiene que $e_t = \lambda_1 d_{1N} + \lambda_2 d_{2N}$, luego, por ser los vectores d_1 y d_2 no negativos, sus $n - m$ últimas componentes deben ser múltiplos de e_t . Es decir $d_{iN} = \mu_i e_t$ con $i \in \{1, 2\}$.

Fijémonos ahora en las m primeras componentes. Al ser los vectores d_i con $i \in \{1, 2\}$ direcciones se cumplirá que $Ad_i = 0$. Desarrollando esta cuenta tenemos

$$Ad_i = (B|N)(d_{iB}|\mu_i e_t)^t = Bd_{iB} + \mu_i Ne_t = Bd_{iB} + \mu_i a_k = 0$$

despejando obtenemos que $d_{iB} = -\mu_i B^{-1}a_k$ con lo que ambas direcciones son equivalentes.

\Rightarrow Sea d una dirección extrema de \mathcal{S} , por tanto un vector no negativo y no nulo. Podemos suponer que d tiene $p + 1$ componentes positivas con $p \in \{0, \dots, n - 1\}$. En primer lugar, procedemos a reordenar el vector de forma que sus p primeras componentes sean positivas, colocando la última componente positiva en la posición $k > m$ (cualquiera donde quepa).

Veamos que las columnas correspondientes a las p primeras componentes del vector d reordenado son linealmente independientes. En caso contrario existirá una combinación lineal no trivial tal que $\sum_{i=1}^p \lambda_i a_i = 0$. Dicho esto, vamos a tratar de construir dos direcciones de \mathcal{S} en función de las cuales d pueda escribirse como combinación lineal positiva, llegando a una contradicción con la extremalidad de d .

Definiendo el vector $\lambda := (\lambda_1, \dots, \lambda_p, 0, \dots, 0)$ y los vectores

$$d_1 = d + \delta \lambda \quad d_2 = d - \delta \lambda$$

siendo δ suficientemente pequeño para que d_1 y d_2 sean no negativos. Nótese que $d = \frac{1}{2}d_1 + \frac{1}{2}d_2$, luego si d_1 y d_2 son direcciones tendríamos una contradicción. Y, en efecto lo son, basta echar las cuentas

$$Ad_i = A(d \pm \delta \lambda) = Ad \pm \delta A\lambda = 0$$

De esta forma se llega a la conclusión de que necesariamente $p \leq m$, lo cual es importante, pues nos dice que si un vector tiene más de m componentes positivas este no puede ser dirección extrema.

En definitiva, si $p = m$ ya tenemos una base B de A , en caso contrario siempre podemos coger columnas adicionales para completar la base (observación 1.2.3). Veamos pues que se cumple lo que se tiene que cumplir, para lo cual basta con, de nuevo, hacer las cuentas.

$$0 = Ad = (B|N)(d_B|d_N)^t = Bd_B + Nd_N = Bd_B + a_k d_k$$

despejando obtenemos que $d_B = -d_k B^{-1}a_k$ y evidentemente $d_N = d_k e_t$, luego tomando $\alpha := d_k$ se tiene el resultado. \blacksquare

Observación 1.2.8 (Finitud). Sobre la finitud de las direcciones extremas de una región factible sigue siendo válida con muy pocas modificaciones (que se dejan al lector) la observación 1.2.5. \diamond

Terminado nuestro viaje por el mundo de la convexidad, podemos internarnos ya en el meollo del asunto, es decir, en desarrollar material teórico que nos permita desarrollar un algoritmo para optimizar funciones lineales condicionadas a variedades afines en el 2^n -ante positivo.

1.3. Teoremas fundamentales

Empezamos esta sección enunciando un teorema que no demostraremos, no porque sea especialmente complicado, sino porque es especialmente largo y su demostración no aporta demasiado a nuestros objetivos. Hablamos del famoso “teorema de representación”.

Teorema 1.3.1 (Teorema de representación). *Sea \mathcal{S} una región factible con p puntos extremos $\{x_1, \dots, x_p\}$ y l direcciones extremas $\{d_1, \dots, d_l\}$. Un punto x está en la región factible si y solo si x es “combinación esotérica” de puntos y direcciones extremas, es decir*

$$x = \sum_{i=1}^p \lambda_i x_i + \sum_{j=1}^l \mu_j d_j$$

con $\lambda_i, \mu_j \geq 0$ y $\sum_{i=1}^p \lambda_i = 1$.

El siguiente teorema es un test de optimalidad para regiones factibles que poseen direcciones extremas.

Teorema 1.3.2 (Test de optimalidad). *Dado un problema de programación lineal con región factible no acotada y direcciones extremas $\{d_1, \dots, d_s\}$, el problema tiene solución óptima si y solo si se cumple que $c^t d_j \geq 0$ para todo $j \in \{1, \dots, s\}$.*

Demostración. Demostremos ambas implicaciones echando mano del teorema de representación.

\Rightarrow Por reducción al absurdo, si la función objetivo alcanzara la solución óptima y hubiera una dirección extrema d_r tal que $c^t d_r < 0$ podemos considerar el punto de la región factible (por el teorema de representación)

$$x_{\mu_r} = \sum_{i=1}^p \lambda_i x_i + \mu_r d_r$$

Veamos cómo evoluciona el valor de la función objetivo para valores grandes de μ_r

$$\lim_{\mu_r \rightarrow \infty} c^t x_{\mu_r} = \lim_{\mu_r \rightarrow \infty} \sum_{i=1}^p \lambda_i c^t x_i + \mu_r c^t d_r = \lim_{\mu_r \rightarrow \infty} \mu_r c^t d_r = -\infty$$

luego es un problema con solución no acotada (absurdo por hipótesis).

\Leftarrow Dado un punto x de la región factible por el teorema de representación se verifica que la función objetivo evaluada en x es

$$c^t x = \sum_{i=1}^p \lambda_i c^t x_i + \sum_{j=1}^s \mu_j c^t d_j$$

el resultado que arroja el segundo sumatorio es positivo, luego si consiguiéramos fusilarlo mejoraríamos el valor de la función objetivo. Para ello basta con coger el punto con representación $x' := \sum_{i=1}^p \lambda_i x_i$. De esta forma

$$c^t x \geq c^t x' = \sum_{i=1}^p \lambda_i c^t x_i$$

más aun, si consideramos el punto extremo x^* tal que $c^t x^* := \min\{c^t x_i : 1 \leq i \leq p\}$ tenemos la cadena de desigualdades

$$c^t x \geq c^t x' \geq \sum_{i=1}^p \lambda_i c^t x^* = c^t x^*$$

de esta forma se tiene que x^* es solución óptima del problema, ya que la función objetivo evaluada en ese punto es menor o igual a la de cualquier otro. ■

Observación 1.3.1 (No acotación). La hipótesis de no acotación del teorema 1.3.2 no es necesaria para la demostración de la implicación a la izquierda.

La demostración de la implicación a la derecha exige la existencia de al menos una dirección extrema, y por tanto la no acotación de la región factible. Esta implicación constituye un criterio de no acotación de la función objetivo en regiones factibles no acotadas. ◇

Observación 1.3.2 (Algoritmo de representación). Con todo lo que tenemos hasta ahora ya tenemos un algoritmo (algoritmo 1) para resolver problemas de programación lineal. Basta con calcular los puntos y direcciones extremas de la región factible, lo cual puede hacerse usando los teoremas 1.2.4 y 1.2.9 y seguir la demostración del test de optimalidad (teorema 1.3.2).

La eficiencia de este algoritmo es pésima pues obliga a calcular todos los puntos extremos, con lo que la eficiencia el algoritmo sería $\mathcal{O}\binom{n}{m}$ siendo n el número de variables de decisión y m el número de restricciones. ◇

Algoritmo 1 Algoritmo de representación.

- 1: Calcular los puntos y direcciones extremas.
 - 2: **si** no hay puntos extremos **entonces**
 - 3: **devolver** problema infactible.
 - 4: **si no**, **si** no hay direcciones extremas **entonces**
 - 5: **devolver** el mejor punto extremo.
 - 6: **si no**
 - 7: {Region no acotada.}
 - 8: Comprobar las hipótesis del teorema 1.3.2.
 - 9: **si** hay solución óptima **entonces**
 - 10: **devolver** el mejor punto extremo.
 - 11: **si no**
 - 12: **devolver** x_{μ_r} , dirección en la que las soluciones decrecen.
 - 13: **fin si**
 - 14: **fin si**
-

La pésima eficiencia del algoritmo basado en el teorema de representación incita seguir desarrollando soporte teórico para un algoritmo mejor.

El siguiente resultado actúa a modo de recopilación de todo lo visto hasta ahora y se presenta más que nada por su recurrente aparición en la literatura como un teorema con nombre propio.

Teorema 1.3.3 (Teorema fundamental de la programación lineal). *Dado un problema de programación lineal en forma estándar se cumplen los siguientes asertos*

1. Si el problema es factible, posee al menos una solución básica factible.
2. Si el problema tiene solución óptima, posee al menos una solución básica factible óptima.
3. Si el problema no tiene solución óptima, o bien es infactible o bien tiene solución no acotada.

Demostración. El primer aserto se corresponde con el contenido del teorema 1.2.6. La segunda afirmación se demuestra en el teorema 1.2.7.

El último apartado es el que tiene algo más de chicha. Distinguimos tres casos según la naturaleza de la región factible. Si la región factible es vacía el problema es, por definición, infactible. En el caso de que la región factible sea acotada, es también compacta.

Esto se debe a que es la imagen inversa de $\{b\}$ (cerrado) vía la función lineal (continua) que tiene a A por matriz asociada, luego la región factible es cerrada y acotada, por tanto, la función objetivo alcanza el mínimo en la región factible y el problema tiene solución óptima (se sale de nuestros casos de estudio).

Si la región factible es no acotada basta con aplicar el teorema 1.3.2. ■

A continuación vamos a presentar un nuevo test de optimalidad de una solución factible que no requiere del cálculo de todas las direcciones extremas. Antes de enunciarlo presentamos la siguiente definición.

Definición 1.3.1 (Costes reducidos). Definimos el **vector de costes reducidos** asociado a una base B como el vector $\bar{c} \in \mathbb{R}^n$ cuyas componentes son

$$\bar{c}_j := c_j - c_B^t B^{-1} a_j$$

justificaremos el nombre y la razón de ser de esta cruel definición tras la demostración del teorema 1.3.4, que consideramos bastante importante.

Teorema 1.3.4 (Test de optimalidad). Si \bar{x} es un punto extremo de \mathcal{S} asociado a la base B y el vector de costes reducidos asociado a B es no negativo entonces \bar{x} es una solución óptima.

Demostración. Sea x un punto arbitrario de \mathcal{S} . Vamos a demostrar que $c^t x \geq c^t \bar{x}$, con lo cual quedaría demostrado el resultado.

Como $x \in \mathcal{S}$ se verifica que $Ax = b$. Expresando esto en términos de la base B tenemos que

$$Ax = (B|N)(x_B|x_N)^t = Bx_B + Nx_N = b \iff x_B = B^{-1}b - B^{-1}Nx_N \quad (1.6)$$

Pasemos x por la función objetivo

$$\begin{aligned} c^t x &= (c_B^t | c_N^t)(x_B | x_N)^t = c_B^t x_B + c_N^t x_N = \\ &= c_B^t (B^{-1}b - B^{-1}Nx_N) + c_N^t x_N = c_B^t B^{-1}b + (c_N^t - c_B^t B^{-1}N)x_N = \\ &= c_B^t B^{-1}b + \left(c_N^t x_N - c_B^t \sum_{j=m+1}^n (B^{-1}a_j)x_j \right) = c_B^t B^{-1}b + \sum_{j=m+1}^n (c_j x_j - c_B^t B^{-1}a_j x_j) = \\ &= c_B^t B^{-1}b + \sum_{j=m+1}^n (c_j - c_B^t B^{-1}a_j)x_j = c_B^t B^{-1}b + \sum_{j=m+1}^n \bar{c}_j x_j \quad (1.7) \end{aligned}$$

Como el último sumatorio arroja por hipótesis un resultado positivo tenemos que

$$c^t x \geq c_B^t B^{-1}b$$

pero resulta que $c_B^t B^{-1}b = c^t \bar{x}$ por el teorema 1.2.4 (compruébese). ■

Observación 1.3.3 (Justificación del nombre). Una interpretación que le podemos dar a las componentes del vector de costes reducidos es la siguiente.

$$\bar{c}_j = c^t(\bar{x} + e_j) - c^t \bar{x}$$

donde e_j es el j -ésimo vector de la base canónica de \mathbb{R}^n y \bar{x} es una solución básica factible (punto extremo).

Lo que quiere decir esta interpretación es que \bar{c}_j es la diferencia entre valor que arroja la función objetivo cuando se la evalúa en un punto extremo y el valor que obtenemos si le sumamos uno a la coordenada j -ésima.

La comprobación de la validez de esta interpretación se hace echando mano de las identidades obtenidas en la demostración del teorema 1.3.4.

Nótese que si $j \leq m$ entonces $\bar{c}_j = 0$ (compruébese). ◇

Teorema 1.3.5 (Test de no acotación). Dada una región factible no vacía \mathcal{S} y un punto extremos \bar{x} asociado a la base B de manera que hay algún coste reducido $\bar{c}_k < 0$ y se verifica que $B^{-1}a_k \leq 0$, entonces el problema tiene solución no acotada.

Demostración. Nótese que $k \in \{m+1, \dots, n\}$ ya que los costes reducidos asociados a las componentes asociadas a B son nulos.

Como por hipótesis $B^{-1}a_k \leq 0$, luego es claro que la región factible posee una dirección extrema, la dada por $d := (-B^{-1}a_k|e_t)^t$ donde $k = m+t$.

De esta forma sabemos que el punto $x_\alpha := \bar{x} + \alpha d \in \mathcal{S}$ para todo $\alpha \geq 0$. Veamos cómo se comporta $c^t x_\alpha$ para valores grandes de α

$$c^t x_\alpha = c^t(\bar{x} + \alpha d) = c^t \bar{x} + \alpha c^t d \stackrel{!}{=} c_B^t B^{-1}b + \alpha c^t d$$

por otra parte tenemos que

$$c^t d = (c_B^t | c_N^t)(-B^{-1}a_k|e_t)^t = -c_B^t B^{-1}a_k + c_N^t e_t = -c_B^t B^{-1}a_k + c_k = \bar{c}_k$$

de manera que $c^t x_\alpha = c_B^t B^{-1}b + \alpha \bar{c}_k$. Al ser \bar{c}_k negativo claramente $\lim_{\alpha \rightarrow \infty} c^t x_\alpha = -\infty$ ■

Observación 1.3.4 (Dirección de decrecimiento). De la demostración del teorema 1.3.5 se deduce que la función objetivo decrece indefinidamente a lo largo de la recta afín de ecuación paramétrica x_α . A esto usualmente lo llamaremos **dirección de decrecimiento** de las soluciones.

Algo similar se desprende de la demostración del teorema 1.3.2 con x_{μ_r} . ◇

Definición 1.3.2 (Vector auxiliar). Dada una matriz A y una base B de A , llamamos **vector auxiliar** asociado a a_k al vector

$$y_k := B^{-1}a_k \in \mathbb{R}^m$$

La única intención de esta definición es compactar un poco la notación para las direcciones extremas. Cabe destacar que no es necesario aprenderse la fórmula, simplemente hay que entender que y_k es el vector a_k escrito en coordenadas de la base B .

Denotaremos por y_{ik} a la i -ésima componente de y_k .

Presentamos a continuación el que probablemente sea el teorema más importante del curso, cuya demostración es debida a Clara Rodríguez.

Teorema 1.3.6 (Mejora de la solución). Sea una región factible \mathcal{S} no vacía y un punto extremo \bar{x} asociado a una base B de manera que hay algún coste reducido $\bar{c}_k < 0$ y se verifica que y_k tiene al menos una componente positiva.

Entonces se tiene que el vector $x' = \bar{x} + \alpha d$ es un punto extremo que mejora la función objetivo respecto a \bar{x} , es decir $c^t x' \leq c^t \bar{x}$. Donde

$$\alpha := \min \left\{ \frac{\bar{x}_i}{y_{ik}} : y_{ik} > 0 \right\} =: \frac{\bar{x}_l}{y_{lk}} \quad d := (-y_k|e_t)^t \text{ con } k = m+t$$

Además $c^t x' < c^t \bar{x}$ si y solo si $\bar{x}_l > 0$.

Demostración. Veamos en primer lugar que x' pertenece a la región factible. Es evidente que $Ax' = b$ (se deja al lector hacer la cuenta), luego solo queda comprobar que $x' \geq 0$. Es claro que las componentes de x' que no están asociadas a la base B son todas positivas ya que

$$x' = (x'_B | x'_N)^t = (B^{-1}b | 0)^t + \alpha(-y_k|e_t)^t \iff x'_N = \alpha e_t \geq 0$$

por tanto, solo nos debemos preocupar de las componentes asociadas a la base. Veamos que son todas no negativas

$$x'_B = \bar{x}_B - \alpha y_k \geq 0 \iff \bar{x}_i - \alpha y_{ik} \geq 0 \text{ con } i \in \{1, \dots, m\}$$

esa última condición se verifica si y solo si $\alpha \leq \frac{\bar{x}_i}{y_{ik}}$ para los $y_{ik} > 0$. Y hemos cogido α expresamente para que esto se cumpla, luego x' está en la región factible.

Veamos ahora que x' es un punto extremo, para lo cual basta con demostrar que el conjunto de vectores $(B \setminus a_l) \cup a_k$ es linealmente independiente. Para mostrar consideramos el conjunto de vectores $B \cup a_k$, que es un sistema de generadores de \mathbb{R}^m .

Resulta que a_l es combinación lineal de los vectores de $(B \setminus a_l) \cup a_k$ ya que

$$x_k = \sum_{i=1}^m y_{ik} a_i = \sum_{\substack{i=1 \\ i \neq l}}^m y_{ik} a_i + y_{lk} a_l$$

como $y_l > 0$ podemos despejar a_l . En efecto

$$a_l = \frac{x_k}{y_{lk}} - \sum_{\substack{i=1 \\ i \neq l}}^m \frac{y_{ik}}{y_{lk}} a_i$$

de donde se desprende que el conjunto $(B \setminus a_l) \cup a_k$ sigue siendo un sistema de generadores de \mathbb{R}^m que además tiene m elementos, luego es una base.

Veamos ahora que x' es una solución mejor que \bar{x} , basta echar las cuentas

$$c^t(\bar{x} + \alpha d) = c^t \bar{x} + \frac{\bar{x}_l}{y_{lk}} c^t d \stackrel{!}{=} c_B^t B^{-1} b + \frac{\bar{x}_l}{y_{lk}} \bar{c}_k \leq c_B^t B^{-1} b = c^t \bar{x}$$

El “además” es evidente. Con lo que concluye la prueba. ■

Con la ayuda estos últimos teoremas podemos desarrollar un algoritmo (mejor que el basado en el teorema de representación) que nos permite hallar la solución a un problema de programación lineal. Este algoritmo es conocido como “algoritmo del Símplex” (algoritmo 2), desarrollado por el matemático estadounidense **George Dantzig** en 1947.

Observación 1.3.5 (Justificación del nombre). El nombre “símplex” que recibe el algoritmo se debe a que las regiones factibles de los problemas de programación lineal en forma estándar tienen estructura geométrica de **poliedros** o **símplices**, o, en inglés **simplex**. ◇

Algoritmo 2 Primera aproximación al algoritmo del Símplex.

Entrada: Punto extremo \bar{x} de la región factible \mathcal{S} .

Salida: Punto extremo x' que mejora o iguala a \bar{x} .

- 1: Aplicar el teorema 1.3.4 para detectar la optimalidad de \bar{x} .
 - 2: **si** \bar{x} es solución óptima **entonces**
 - 3: **devolver** \bar{x} .
 - 4: **si no**
 - 5: Aplicar el teorema 1.3.5 para detectar la no acotación.
 - 6: **si** el problema es no acotado **entonces**
 - 7: **devolver** x_α , dirección de decrecimiento de las soluciones.
 - 8: **si no**
 - 9: Calcular una solución mejor usando el teorema 1.3.6.
 - 10: **devolver** x' , la solución mejorada.
 - 11: **fin si**
 - 12: **fin si**
-

Observación 1.3.6 (Acertijos en la oscuridad). El algoritmo 2 deja ciertas lagunas. Por ejemplo, no está claro que la aplicación reiterada del algoritmo termine devolviéndonos una solución óptima (podría quedarse estancado).

Además, tampoco se especifica cómo se calcula el primer punto extremo, ni se establece ninguna regla acerca de cómo calcular los costes reducidos necesarios para aplicar los teoremas.

Este último punto puede dar lugar (con una implementación inocente) a un algoritmo extremadamente ineficiente.

Otro asunto a discutir sería el de, en caso de haber varios costes reducidos negativos, cuál elegir para aplicar el teorema 1.3.6. ◇

Todas estas cuestiones se discutirán en el capítulo siguiente.

Capítulo 2

Algoritmo del Símplex

Este es un capítulo dedicado a aclarar las lagunas que presenta el algoritmo 2, desarrollando ya un algoritmo completo que tenga en cuenta todas las contingencias habidas y por haber, el algoritmo del Símplex.

2.1. Cambios de base

Llegados a este punto nos preguntamos qué datos necesita el algoritmo 2 para ejecutarse. Para obtener la respuesta basta con mirar con cuidado los teoremas en los que se basa, con lo que concluimos que son necesarios

- Las componentes asociadas a la base (o componentes básicas) del punto extremo. Para calcular qué vector sale de la base al mejorar el punto extremo (teorema 1.3.6) y para devolverlas cuando se detecta la optimalidad.
- El vector de costes reducidos asociado a la base del punto extremo para aplicar los tests de optimalidad y no acotación. Además de para decidir qué vector entra a la base para mejorar el punto extremo.
- Los vectores auxiliares y_j para aplicar los tests de no acotación (y en su caso devolver la dirección en la que la función objetivo decrece indefinidamente) y para calcular qué vector sale de la base al mejorar el punto extremo.
- El valor de la función objetivo al ser evaluada en el punto extremo, para devolverlo cuando se halle la solución óptima.

Cuando cambiamos de punto extremo, el teorema de mejora nos da explícitamente la nueva base asociada al nuevo punto. Este nuevo punto tendrá otras componentes asociadas a la base e inducirá nuevos vectores de costes reducidos y vectores auxiliares que necesitan ser calculados para ejecutar la nueva iteración.

La forma inocente de calcular todas estas cosas pasa por invertir la base asociada al nuevo punto extremo, lo cual es pecado mortal, pues es un trabajo computacionalmente muy pesado (del orden de $\mathcal{O}(n^3)$).

En lugar de eso lo que haremos será calcular todos los nuevos valores necesarios a partir de los anteriores. A ver que esto es posible y cómo nos dedicamos en esta sección.

2.1.1. Vectores auxiliares y componentes básicas

En primer lugar nos planteamos la ecuación (1.6) respecto de la base asociada al punto extremo original, B , y la nueva base $B' = (B \setminus a_l) \cup a_k$.

$$x_B = \overline{x_B} - B^{-1}N x_N \quad (2.1)$$

$$x_{B'} = \overline{x_{B'}} - B'^{-1}N' x_{N'} \quad (2.2)$$

Observación 2.1.1 (Vectores auxiliares). Nótese que, por las propiedades del producto de matrices se tiene que

$$\begin{aligned} B^{-1}N &= B^{-1}(a_{m+1} \cdots a_n) = (B^{-1}a_{m+1} \cdots B^{-1}a_n) = (y_{m+1} \cdots y_n) \\ B'^{-1}N' &= (y'_{m+1} \cdots y'_{k-1} | y'_l | y'_{k+1} \cdots y'_n) \end{aligned} \quad \diamond$$

Planteando las ecuaciones (2.1) y (2.2) componente a componente nos encontramos con

$$x_s = \overline{x}_s - \sum_{\substack{j=m+1 \\ j \neq k}}^n y_{sj}x_j - y_{sk}x_k \quad (2.3)$$

$$x_s = \overline{x}'_s - \sum_{\substack{j=m+1 \\ j \neq k}}^n y'_{sj}x_j - y'_{sl}x_l \quad (2.4)$$

Una vez organizado nuestro espacio de trabajo como lo está ahora, vayamos por partes. Por un lado consideramos la ecuación (2.3) para $s = l$. Despejando x_k de esta ecuación obtenemos (¡compruébese!)

$$x_k = \frac{\overline{x}_l}{y_{lk}} - \sum_{\substack{j=m+1 \\ j \neq k}}^n \frac{y_{lj}}{y_{lk}}x_j - \frac{1}{y_{lk}}x_l \quad (2.5)$$

Nótese que el despeje que hemos hecho es válido, ya que por el teorema 1.3.6 tenemos garantizado que $y_{lk} > 0$. Ahora, si sustituimos el valor de x_k dado por la ecuación (2.5) en la ecuación (2.3) obtenemos

$$x_s = \overline{x}_s - \frac{y_{sk}\overline{x}_l}{y_{lk}} + \sum_{\substack{j=m+1 \\ j \neq k}}^n \left(\frac{y_{sj}y_{lj}}{y_{lk}} - y_{sj} \right) x_j + \frac{y_{sk}}{y_{lk}}x_l$$

esta ecuación y la ecuación (2.4) son dos ecuaciones lineales equivalentes. Por tanto, son la una múltiplo de la otra, no obstante, al tener x_s el mismo coeficiente en ambas ecuaciones, estas deben ser iguales. De esto se desprende, comparando ambas ecuaciones

$$\overline{x}'_s = \overline{x}_s - \frac{y_{sk}\overline{x}_l}{y_{lk}} \quad y'_{sj} = y_{sj} - \frac{y_{sj}y_{lj}}{y_{lk}} \quad y'_{sl} = -\frac{y_{sk}}{y_{lk}} \quad (2.6)$$

para $s \in \{1, \dots, m\} \setminus \{l\}$ y con $j \in \{m+1, \dots, n\} \setminus \{k\}$. En el caso $s = l$ estas expresiones también son válidas (aunque no nos importa mucho).

Nos queda pues el trabajo de hallar expresiones para \overline{x}'_k , la coordenada k -ésima del nuevo punto extremo, e y'_{kj} con $j \in \{m+1, \dots, n\} \setminus \{k\}$ (las columnas de N' , excepto la columna l , que ya se quedó calculada) ya que y'_j donde j es un índice correspondiente a las columnas de B' es e_j (véase definición 1.3.2).

Cosideramos ahora la ecuación (2.4) en el caso $s = k$. Dicha ecuación y (2.5) son ecuaciones lineales equivalentes, de hecho iguales (siguiendo el razonamiento anterior). Por ende basta compararlas para obtener

$$\overline{x}'_k = \frac{\overline{x}_l}{y_{lk}} \quad y'_{kj} = \frac{y_{lj}}{y_{lk}} \quad y'_{kl} = \frac{1}{y_{lk}} \quad (2.7)$$

2.1.2. Costes reducidos y función objetivo

Echando mano de la ecuación (1.7) respecto de las bases B y B' obtenemos

$$c^t x = c_B^t \overline{x}_B + \sum_{\substack{j=m+1 \\ j \neq k}}^n \overline{c}_j x_j + \overline{c}_k x_k \quad (2.8)$$

$$c^t x = c_{B'}^t \overline{x}_{B'} + \sum_{\substack{j=m+1 \\ j \neq k}}^n \overline{c}'_j x_j + \overline{c}'_l x_l \quad (2.9)$$

Sustituyendo el valor de x_k de (2.5) en (2.8) obtenemos

$$c^t x = c_B^t \overline{x_B} + \overline{c_k} \frac{\overline{x_l}}{y_{lk}} + \sum_{\substack{j=m+1 \\ j \neq k}}^n \left(\overline{c_j} - \overline{c_k} \frac{y_{lj}}{y_{lk}} \right) x_j - \overline{c_k} \frac{1}{y_{lk}} x_l$$

tanto esta ecuación como la (2.9) son expresiones analíticas de la misma función lineal respecto de las mismas bases (que no tienen nada que ver con las bases asociadas a la matriz del problema). Esto quiere decir que ambas expresiones son iguales, luego comparándolas obtenemos

$$c_{B'}^t \overline{x_{B'}} = c_B^t \overline{x_B} + \overline{c_k} \frac{\overline{x_l}}{y_{lk}} \quad \overline{c_j} = \overline{c_j} - \overline{c_k} \frac{y_{lj}}{y_{lk}} \quad \overline{c_l} = -\overline{c_k} \frac{1}{y_{lk}} \quad (2.10)$$

De esta forma, las ecuaciones (2.10), (2.6) y (2.7) nos proporcionan las fórmulas que andábamos buscando.

2.2. Tabla del Simplex. Pivotajes

En esta sección introducimos la llamada **tabla del simplex**, que no es más que una forma elegante de implementar las fórmulas de cambio de base deducidas en la sección anterior. Además, evita su memorización.

Sea un problema de programación lineal en forma estándar del que suponemos conocido un punto extremo de su región factible, es decir, una base B .

Consideremos el sistema de ecuaciones lineales asociado a dicho problema y multipliquémoslo a ambos lados por B^{-1} .

$$\begin{aligned} Ax = b &\iff (B|N)(x_B|x_N)^t = b \iff B^{-1}(B|N)(x_B|x_N)^t = B^{-1}b \iff \\ &\iff (B^{-1}B|B^{-1}N)(x_B|x_N)^t = \overline{x_B} \iff (I_m|y_{m+1} \cdots y_n)(x_B|x_N)^t = \overline{x_B} \end{aligned} \quad (2.11)$$

La igualdad final de la ecuación (2.11) puede representarse como una tabla de la siguiente manera

B	x_1	\cdots	x_l	\cdots	x_m	x_{m+1}	\cdots	x_k	\cdots	x_n	$\overline{x_B}$
x_1	1	\cdots	0	\cdots	0	$y_{1,m+1}$	\cdots	y_{1k}	\cdots	y_{1n}	$\overline{x_1}$
\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots
x_l	0	\cdots	1	\cdots	0	$y_{l,m+1}$	\cdots	y_{lk}	\cdots	y_{ln}	$\overline{x_l}$
\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots
x_m	0	\cdots	0	\cdots	1	$y_{m,m+1}$	\cdots	y_{mk}	\cdots	y_{mn}	$\overline{x_m}$

Tabla 2.1: Primera aproximación a la tabla del Simplex.

La virtud de representar un problema de programación lineal de esta forma es que los cambios de base son “automáticos” en cierto sentido. Supongamos que queremos cambiar de punto extremo de forma que la nueva base es $B' = (B \setminus a_l) \cup a_k$. Siguiendo las fórmulas de la sección anterior, la tabla asociada a la nueva base sería

B'	x_1	\vdots	x_l	\vdots	x_m	x_{m+1}	\vdots	x_k	\vdots	x_n	$\overline{x_{B'}}$
x_1	1	\vdots	$-\frac{y_{1k}}{y_{lk}}$	\vdots	0	$y_{1,m+1} - y_{1k} \frac{y_{l,m+1}}{y_{lk}}$	\vdots	0	\vdots	$y_{1n} - y_{1k} \frac{y_{ln}}{y_{lk}}$	$\overline{x_1} - y_{1k} \frac{\overline{x_l}}{y_{lk}}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_k	0	\vdots	$\frac{1}{y_{lk}}$	\vdots	0	$\frac{y_{l,m+1}}{y_{lk}}$	\vdots	1	\vdots	$\frac{y_{ln}}{y_{lk}}$	$\frac{\overline{x_l}}{y_{lk}}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_m	0	\vdots	$-\frac{y_{mk}}{y_{lk}}$	\vdots	1	$y_{m,m+1} - y_{mk} \frac{y_{l,m+1}}{y_{lk}}$	\vdots	0	\vdots	$y_{mn} - y_{mk} \frac{y_{ln}}{y_{lk}}$	$\overline{x_m} - y_{mk} \frac{\overline{x_l}}{y_{lk}}$

Tabla 2.2: Tabla del problema respecto de la base B' .

Si nos fijamos, la nueva tabla puede verse como el resultado de aplicar el algoritmo de Gauss-Jordan en la columna k -ésima, es decir, considerando la tabla como una matriz, usar las transformaciones elementales de matrices para convertir el elemento y_{lk} en un 1 y “hacer ceros” en el resto de la columna. Esto es maravilloso porque puede implementarse en ordenador de forma casi trivial.

La mala noticia es que la tabla 2.2 no tiene todos los datos necesarios para que el algoritmo se ejecute. En concreto, faltan los costes reducidos y el valor de la función objetivo.

La gran noticia sin embargo (y prueba irrefutable de que los dioses son benévolos de cuando en cuando) es que podemos completar la tabla 2.2 de manera que lleve todos los datos necesarios y además la implementación de los cambios de base no varíe en absoluto. En efecto, si consideramos la tabla

B	x_1	\cdots	x_l	\cdots	x_m	x_{m+1}	\cdots	x_k	\cdots	x_n	$\overline{x_B}$
x_1	1	\cdots	0	\cdots	0	$y_{1,m+1}$	\cdots	y_{1k}	\cdots	y_{1n}	$\overline{x_1}$
\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots
x_l	0	\cdots	1	\cdots	0	$y_{l,m+1}$	\cdots	y_{lk}	\cdots	y_{ln}	$\overline{x_l}$
\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots	\cdots
x_m	0	\cdots	0	\cdots	1	$y_{m,m+1}$	\cdots	y_{mk}	\cdots	y_{mn}	$\overline{x_m}$
\overline{c}	0	\cdots	0	\cdots	0	$\overline{c_{m+1}}$	\cdots	$\overline{c_k}$	\cdots	$\overline{c_n}$	$-(c_B^t \overline{x_B})$

Tabla 2.3: Tabla del Símplex.

la tabla asociada a la base B' será

B'	x_1	\vdots	x_l	\vdots	x_m	x_{m+1}	\vdots	x_k	\vdots	x_n	$\overline{x_{B'}}$
x_1	1	\vdots	$-\frac{y_{1k}}{y_{lk}}$	\vdots	0	$y_{1,m+1} - y_{1k} \frac{y_{l,m+1}}{y_{lk}}$	\vdots	0	\vdots	$y_{1n} - y_{1k} \frac{y_{ln}}{y_{lk}}$	$\overline{x_1} - y_{1k} \frac{\overline{x_l}}{y_{lk}}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_k	0	\vdots	$\frac{1}{y_{lk}}$	\vdots	0	$\frac{y_{l,m+1}}{y_{lk}}$	\vdots	1	\vdots	$\frac{y_{ln}}{y_{lk}}$	$\frac{\overline{x_l}}{y_{lk}}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
x_m	0	\vdots	$-\frac{y_{mk}}{y_{lk}}$	\vdots	1	$y_{m,m+1} - y_{mk} \frac{y_{l,m+1}}{y_{lk}}$	\vdots	0	\vdots	$y_{mn} - y_{mk} \frac{y_{ln}}{y_{lk}}$	$\overline{x_m} - y_{mk} \frac{\overline{x_l}}{y_{lk}}$
$\overline{c'}$	0	\vdots	$-\overline{c_k} \frac{1}{y_{lk}}$	\vdots	0	$\overline{c_{m+1}} - \overline{c_k} \frac{y_{l,m+1}}{y_{lk}}$	\vdots	0	\vdots	$\overline{c_n} - \overline{c_k} \frac{y_{ln}}{y_{lk}}$	$-c_{B'}^t \overline{x_{B'}} - \overline{c_k} \frac{\overline{x_l}}{y_{lk}}$

Tabla 2.4: Tabla del problema respecto de la base B' .

Como se observa, la tabla del Símplex tiene en su última fila el vector de costes reducidos y el **opuesto** al valor que toma la función objetivo en el punto extremo asociado a la base que corresponda. La razón para guardar el opuesto y no el valor a secas es que si guardamos el opuesto podemos seguir haciendo los cambios de base como si aplicáramos parcialmente el algoritmo de Gauss-Jordan, en caso contrario no podríamos hacerlo.

Observación 2.2.1 (Notación). Es habitual encontrarse con que la casilla correspondiente a la función objetivo en la tabla del Símplex contiene la expresión $z - (c_B^t \overline{x_B})$. Esto no supone ninguna variación en absolutamente nada, es simplemente notación, añadir una z al principio, sin más. \diamond

A la operación de cambiar de base una tabla se la denomina **pivotaje** y al elemento y_{lk} se le denomina **pivote**.

2.3. Punto extremo inicial

Aunque el trabajo duro ya está hecho, todavía quedan preguntas por resolver, por ejemplo, cómo obtener el punto extremo inicial (si lo hay, ya que el problema podría ser infactible) y todos los datos necesarios asociados a este de forma eficiente.

2.3.1. Método de las dos fases

Encontrar bases de matrices es un trabajo computacionalmente costoso, en el caso peor, que no haya base alguna, es del orden de $\mathcal{O}\binom{n}{m}$ (eso si las comprobaciones intermedias tuvieran coste constante, que no lo tienen). Razón por la cual necesitamos algún tipo de sustitutivo a este método de fuerza bruta.

Lo que exponemos a continuación es conocido como **método de las dos fases** y únicamente es aplicable a problemas en forma estándar con $b \geq 0$. Esto no supone ninguna pérdida de generalidad ya que siempre podemos multiplicar la restricción correspondiente a un $b_i < 0$ por -1 , obteniendo una restricción equivalente y, por tanto, un problema equivalente.

A un problema en las hipótesis anteriormente expuestas que tenga a A por matriz de coeficientes de las restricciones, se le asocia otro problema al que llamaremos **problema artificial**. Dicho problema es el siguiente

$$\begin{aligned} \text{mín } w(x|x_a)^t &:= \sum_{i=1}^m x_i^a \\ \text{Sujeto a: } (A|I_m)(x|x_a)^t &= b, \quad x \geq 0, \quad x_a \geq 0 \end{aligned}$$

es decir, el problema resultante de considerar las restricciones

$$a_{i1}x_1 + \cdots + a_{in}x_n + x_i^a = b_i$$

para $i \in \{1, \dots, m\}$, cuya matriz asociada es $(A|I_m)$. A las nuevas variables x_i^a se las conoce como **variables artificiales**. Además, la función objetivo se sustituye por $w \equiv \sum_{i=1}^m x_i^a$.

Entre las buenas propiedades de este nuevo problema es que tiene una base trivial, la identidad, situada convenientemente en las últimas columnas (lo cual el ordenador agradece).

Pero la cosa no queda aquí, ya que el problema artificial no es un problema no acotado. En efecto, por las restricciones de no negatividad, la función objetivo está acotada inferiormente por 0. Además, el problema artificial es factible, bastando considerar el vector $(0|b)^t \in \mathbb{R}^{n+m}$ como solución factible. Esta es la razón por la que exigimos $b \geq 0$.

Con esto, por el teorema fundamental de la programación lineal (teorema 1.3.3), sabemos que el problema artificial tiene solución óptima. Por si esto fuera poco, obtenemos casi gratis un test de factibilidad para el problema original.

Lema 2.3.1 (Test de factibilidad). *El problema original es factible si y solo si el problema artificial posee una solución óptima $(\bar{x}|\bar{x}_a)^t$ con $\bar{x}_a = 0$.*

Demostración. Demostraremos la implicación a la derecha, para descubrir después que si miramos la demostración con amor, y del revés, la otra implicación también está demostrada.

Si el problema original es factible, entonces habrá un $x \geq 0$ tal que $Ax = b$. En tal caso es claro que el vector $(x|0)^t$ es solución factible del problema artificial (¡compruébese!). Como resulta que $w(x|0)^t = 0$, por la acotación inferior de w tenemos que $(x|0)^t$ es solución óptima del problema artificial con $\bar{x}_a = 0$. ■

Observación 2.3.1 (Sutileza). Si el problema artificial posee una solución óptima x^* con $\bar{x}_a = 0$, todas sus soluciones óptimas x' tendrán $\bar{x}_a = 0$, ya que, en caso contrario $w(x^*) < w(x')$, lo cual es absurdo. ◇

Dicho esto, es claro que, dado un problema de programación lineal dentro de nuestras hipótesis, podemos considerar el problema artificial asociado y resolverlo mediante el algoritmo del Símplex que ya tenemos desarrollado, siendo el rellenado de la tabla inicial (y la determinación del primer punto extremo) trivial, ya que $B = I_m$, por tanto la tabla del Símplex es la correspondiente a la matriz $(A|I_m|b)$ añadiendo como última fila el vector de costes reducidos y el opuesto del valor de la función objetivo.

Cabe destacar que el cálculo del vector de costes reducidos es bastante trivial computacionalmente ya que no hay que invertir ninguna base, simplemente $\bar{w}_j = w_j - w_B^t a_j$.

Una vez hallada la solución óptima al problema artificial, podremos usar el lema 2.3.1 para decidir sobre la factibilidad o no del problema original. En caso de que este resulte factible, la base asociada a la solución óptima encontrada será base del problema original (ya que todas las

columnas de la base están asociadas a columnas de la matriz original). Con esto, ya podríamos aplicar el algoritmo del Simplex para resolver el problema original.

No obstante, cabría preguntarse si es computacionalmente costoso rellenar la tabla del simplex del problema original respecto de la base B dada (es decir, ¿hay que invertir B ?). La respuesta es no, ya que necesitamos calcular la matriz

$$B^{-1}(A|b) = (B^{-1}a_1 \cdots B^{-1}a_n | B^{-1}b)$$

y la matriz asociada a la tabla asociada a la solución óptima del problema artificial es

$$B^{-1}(A|I_m|b) = (B^{-1}a_1 \cdots B^{-1}a_n | B^{-1}e_1 \cdots B^{-1}e_m | B^{-1}b) = (B^{-1}A | B^{-1} | B^{-1}b)$$

luego basta con tomar la misma tabla suprimiendo las columnas asociadas a las variables artificiales.

En cuanto al cálculo de los costes reducidos, aunque ya tenemos invertida la matriz B y podríamos hacerlo “a capón”, no es recomendable, pues multiplicar matrices es computacionalmente costoso.

En lugar de eso, lo que podemos hacer es añadir una fila más a la tabla del Simplex del problema artificial, donde ir calculando (mediante los pivotajes) los costes reducidos asociados a la función objetivo $z := c^t x$ del problema original (nótese que no hay ningún problema).

De esta forma, basta con consultar la tabla asociada a B del problema artificial para rellenar la tabla inicial del problema original, que ya puede ser resuelto usando el algoritmo del Simplex conocido. Organizemos toda esta literatura.

Algoritmo 3 Algoritmo de las dos fases.

- 1: {Primera fase}
 - 2: Construir el problema artificial
 - 3: Resolver el problema artificial (algoritmo 2) repetidas veces.
 - 4: Aplicar el test de factibilidad (lema 2.3.1)
 - 5: **si** es factible **entonces**
 - 6: {Segunda fase}
 - 7: Rellenar la primera tabla con los trucos vistos.
 - 8: Resolver el problema original (algoritmo 2) repetidas veces.
 - 9: **si no**
 - 10: **devolver** Infactible
 - 11: **fin si**
-

2.3.2. Método de las penalizaciones (Big M)

2.4. Prevención de bucles

2.4.1. Criterios de entrada y salida de la base

2.4.2. Regla lexicográfica

En este apartado exponemos un criterio de salida de la base, al que llamamos *regla de la razón léxico-mínima* o simplemente *regla lexicográfica*. Lo que hace útil a este criterio es que, como veremos al finalizar la sección, es un criterio que evita la aparición de bucles, de forma que garantiza la convergencia del algoritmo a una solución óptima (cuando el problema la posea).

Antes de comenzar introduzcamos las siguientes definiciones.

Definición 2.4.1 (Lexicográficamente positivo). Un vector $x \in \mathbb{R}^n$ se dice *lexicográficamente positivo* si es no nulo y su primera componente no nula es positiva.

Esto lo denotamos por $x >_L 0$.

Definición 2.4.2 (Orden lexicográfico). Dados dos vectores $x, y \in \mathbb{R}^n$ decimos que x es *lexicográficamente mayor* que y si $x - y$ es lexicográficamente positivo. Sintéticamente

$$x >_L y \iff x - y >_L 0$$

Esta relación define un orden total estricto en $\mathbb{R}^n \setminus \{0\}$.

Hechas estas consideraciones previas, supongamos que en cierta iteración del algoritmo se decide que la k -ésima columna entra en la base, mientras que a la hora de decidir la variable que sale, se producen empates con la regla de la razón mínima.

En tal caso consideramos la matriz $V_B := (\overline{x_B} | B^{-1})$ donde B es la base “vieja” que vamos a sustituir por la base B' (aún por calcular).

Denotaremos por V_B^i a la fila i -ésima de la matriz V_B .

Observación 2.4.1 (Cálculo de V_B). Nótese que el cálculo de la matriz V_B no supone ningún coste adicional para el ordenador en el caso de que la base inicial sea la identidad, cosa que siempre pasará si utilizamos el método de las dos fases o de las penalizaciones.

Esto se debe a que la tabla del simplex (salvo el vector de costes y la función objetivo) viene dada por la matriz

$$B^{-1}(A|b) = B^{-1}(N|I_m|b) = (B^{-1}N|B^{-1}|\overline{x_B})$$

con lo que tenemos B^{-1} en las columnas correspondientes a la base inicial, con lo que automáticamente tenemos V_B . \diamond

Dicho esto, la **regla lexicográfica** dicta que saldrá de la base la columna l -ésima si y solo si se verifica

$$y_{lk} > 0 \quad \frac{V_B^i}{y_{ik}} >_L \frac{V_B^l}{y_{lk}} \quad (2.12)$$

para todo $i \in \{1, \dots, m\} \setminus \{l\}$ con $y_{ik} > 0$.

Antes de continuar presentemos dos observaciones interesantes.

Observación 2.4.2 (Generalización). Nótese que la regla lexicográfica no es más que una generalización de la regla de la razón mínima, en la que en lugar de hacer una comparación lexicográfica de los vectores $V_B^i \frac{1}{y_{ik}}$ y $V_B^l \frac{1}{y_{lk}}$, únicamente se comparaban sus primeras componentes.

Esto sugiere una implementación natural de la comparación lexicográfica, que únicamente necesita comparar $V_B^i \frac{1}{y_{ik}}$ y $V_B^l \frac{1}{y_{lk}}$ componente a componente hasta que la comparación arroje un resultado no nulo. \diamond

Observación 2.4.3 (Imposibilidad de empates). Es interesante observar también que la regla lexicográfica no permite los empates, ya que, en caso de que varios vectores empataran se daría la situación

$$\frac{V_B^i}{y_{ik}} >_L \frac{V_B^l}{y_{lk}} \iff \frac{y_{lk}}{y_{ik}} V_B^i = V_B^l$$

Luego B^{-1} tendría dos filas proporcionales (lo cual va contra su invertibilidad). \diamond

Para finalizar, comprobemos que, efectivamente, la regla lexicográfica es una regla de prevención de ciclos, para lo cual necesitamos introducir una definición.

Definición 2.4.3 (Valor vectorial lexicográfico). Definimos el **valor vectorial lexicográfico** asociado a la base B como el vector $v_B := \sum_{i=1}^m c_i V_B^i$.

La idea de la demostración será comparar los valores lexicográficos de una base B y el de la base B' resultante de aplicar el cambio de base según la regla lexicográfica, viendo que $v_{B'} <_L v_B$, siendo imposible que el algoritmo analice dos veces una misma base.

Antes de pasar a demostrar esto, observemos la relación que hay entre $V_{B'}^i$ y V_B^i . Simplemente fijándonos en las fórmulas del pivoteaje tenemos que

$$V_{B'}^k = \frac{V_B^l}{y_{lk}} \quad V_{B'}^i = V_B^i - \frac{y_{ik}}{y_{lk}} V_B^l \quad (2.13)$$

Observación 2.4.4 (Positividad). Nótese además que si la primera base considerada en el algoritmo es la identidad, es claro que $V_{I_m}^i >_L 0$, pero no solo eso, la aplicación de la regla lexicográfica en este supuesto asegura que $V_B^i >_L 0$ para toda base considerada.

Para probar esto basta echar un vistazo a las ecuaciones (2.12) y (2.13) (se deja al lector). \diamond

Dicho esto, ya estamos listos para demostrar lo que queremos.

Proposición 2.4.1 (Buena definición). *La regla lexicográfica es una regla de prevención de ciclos.*

Demostración. Basta desarrollar la siguiente cuenta

$$\begin{aligned}
 v_{B'} &:= \sum_{\substack{i=1 \\ i \neq l}}^m c_i V_{B'}^i + c_k V_{B'}^k = \sum_{\substack{i=1 \\ i \neq l}}^m c_i \left(V_B^i - \frac{y_{ik}}{y_{lk}} V_B^l \right) + c_k \frac{V_B^l}{y_{lk}} = \\
 &= \sum_{\substack{i=1 \\ i \neq l}}^m c_i V_B^i + \frac{V_B^l}{y_{lk}} \left(c_k - \sum_{\substack{i=1 \\ i \neq l}}^m c_i y_{ik} \right) = \sum_{\substack{i=1 \\ i \neq l}}^m c_i V_B^i + \overline{c_k} \frac{V_B^l}{y_{lk}} <_L \sum_{i=1}^m c_i V_B^i =: v_B \quad \blacksquare
 \end{aligned}$$

2.4.3. Regla de Bland

Presentamos a continuación otra regla de prevención de ciclos, debida a Robert G. Bland (1977), y que, como es evidente, es conocida como **regla de Bland**. Esta regla es muy sencilla y constituye un criterio de entrada y salida a la base.

Lo que dice la regla es lo siguiente: de todas las columnas candidatas a entrar en la base escogemos la de menor índice. Análogamente, de todas las columnas candidatas a salir de la base (que empatan con la regla de la razón mínima), escogemos también la de menor índice.

Capítulo 3

Dualidad

Parte II

Programación entera

Capítulo 4

Modelización

Capítulo 5

Ramificación y acotación

Parte III

Programación no lineal

Parte IV

Anexos

Índice de términos

- 2^n -ante positivo, 3
- base, 10
- combinación
 - lineal convexa, 9
- conjunto
 - convexo, 8
- dirección, 14
 - de decrecimiento de las soluciones, 19
 - equivalente, 14
 - extrema, 14
- forma
 - canónica primera, 5
 - canónica segunda, 5
 - estándar, 4
- función
 - objetivo, 4
- geometría
 - computacional, 8
- lexicográficamente
 - mayor, 26
 - positivo, 26
- método
 - de las dos fases, 25
- matriz
 - de coeficientes de las restricciones, 4
- pivotaje, 24
- pivote, 24
- problema
 - artificial, 25
 - infactible, 7
- programación
 - lineal, 3
- punto
 - extremo, 10
- región
 - factible, 7
- regla
 - de Bland, 28
 - de la razón léxico mínima, 26
 - lexicográfica, 26
- restricciones, 4
- solución, 7
 - óptima, 7
 - básica factible, 12
 - factible, 7
 - no acotada, 7
- tabla
 - del símplex, 23
- valor vectorial lexicográfico, 27
- variable
 - artificial, 25
 - de holgura, 6
- vector
 - auxiliar, 19
 - de coeficientes de la función objetivo, 4
 - de costes reducidos, 18
 - de términos independientes, 4
 - de variables de decisión, 4
 - no negativo, 3